

# HybridRAG-BN: A Retrieval-Augmented Framework with Fine-Tuned Verification for Bangla KBQA

Rathijit Aich, Nirjhar Das, Mahfuzulhoq Chowdhury

Department of Computer Science and Engineering

Chittagong University of Engineering & Technology

Chattogram, Bangladesh

{aichrathijit, nirjhardasami}@gmail.com, mahfuz@cuet.ac.bd

**Abstract**—Knowledge-base question answering (KBQA) systems rely on effective retrieval and reasoning mechanisms to generate accurate answers from external knowledge sources. However, developing reliable KBQA systems for low-resource languages such as Bangla remains challenging due to limited retrieval-focused research, scarce language resources, and difficulties in grounding generated responses in external knowledge. In this work, we propose HybridRAG-BN, a retrieval-augmented framework for Bangla KBQA that integrates hybrid retrieval using BM25 and BGE-M3, answer generation using the GGUF version of Gemma-4-31B-Instruct, and a LoRA-fine-tuned Gemma-4-31B-Instruct model for answer verification and refinement. To further improve robustness, the framework incorporates a post-processing stage that addresses unresolved cases through fallback answer replacement and DuckDuckGo-assisted retrieval. Experimental results demonstrate the effectiveness of the proposed framework, achieving token-level F1 scores of 0.71654 and 0.72912 on the public and private leaderboards, respectively, securing first place in the competition.

## I. INTRODUCTION

This work was originally developed for the IEEE Computer Society CUET Student Branch Chapter’s ML Contest 2.0. Knowledge-base question answering (KBQA) systems aim to answer natural language queries by retrieving and utilizing relevant information from external knowledge sources. Although Retrieval-Augmented Generation (RAG) has significantly improved fact-grounded question-answering in high-resource languages, developing reliable Bangla KBQA systems remains challenging due to limited retrieval-focused research, linguistic complexity, and scarce language resources.

In this work, we present HybridRAG-BN, a retrieval-augmented framework designed to improve the accuracy and robustness of Bangla KBQA. Our system was developed and evaluated on a dataset derived from the Indic-RAG-Suite [1], provided as part of the “Are You Sure LLM Is Enough? – Intra CUET ML Contest 2.0 (Advanced Track)”, organized by the IEEE Computer Society CUET Student Branch Chapter. The dataset consists of approximately 3,000 question-answer-reasoning training triples, 1,500 test questions and a knowledge base containing approximately 6,500 Bangla Wikipedia pages.

To address retrieval and reasoning challenges in low-resource settings, the proposed framework consists of four stages:

- Hybrid retrieval using BM25 and BGE-M3 to combine lexical and semantic matching.
- Answer generation using the GGUF version of Gemma-4-31B-Instruct.
- Answer verification and refinement using a LoRA fine-tuned Gemma-4-31B-Instruct model.
- Post-processing through fallback answer replacement and external DuckDuckGo-assisted retrieval for unresolved cases.

## II. METHODOLOGY

Figure 1 presents an overview of the proposed framework, including the two preprocessing-based approaches, the fine-tuned answer verification module, and the post-processing stage used to generate the final prediction.

### A. Knowledge Base Preprocessing and Chunking

1) **Approach 1 – Precision-Based:** The raw Bangla Wikipedia knowledge base was first reconstructed at the page level by splitting the corpus using Wikipedia page markers. Each page was then cleaned by removing recurring boilerplate sections, including page headers, footers, navigation blocks, and language-list sections commonly found in Wikipedia dumps.

a) **Removed Boilerplate Blocks:** The preprocessing pipeline removed five categories of non-informative content. These included recurring header and footer sections, two variants of tool and navigation blocks commonly embedded within Wikipedia pages, and translation or language-selection blocks. The language-list sections were identified using markers such as “ন টি ভাষা” and আন্তঃউইকি সংযোগ সম্পাদনা. Removing these components reduced noise in the knowledge base while preserving the main article content for retrieval.

The cleaned corpus was then divided into overlapping text chunks for retrieval. Chunks were generated with a target length of approximately 1000 characters and an overlap of 150 characters. To preserve semantic coherence, paragraph




Figure 1. Overview of the proposed question-answering framework.

breaks and predefined boundary markers (such as “|” and “.”) were preferred as chunk boundaries whenever possible. If no suitable boundary was found, a character-based split was applied. The overlap helped preserve contextual information that might otherwise be fragmented across chunk boundaries.

2) **Approach 2 – Coverage-Based:** Approach 2 was designed as a less aggressive preprocessing pipeline. In this configuration, only the header block, footer block, and the first type of tool/navigation block were removed.

The cleaned corpus was subsequently divided into overlapping text chunks using the same boundary-aware chunking strategy employed in Approach 1. However, the target chunk size was reduced to approximately 800 characters while maintaining an overlap of 150 characters between consecutive chunks. Table I shows the comparison.

Table I  
CHUNK STATISTICS FOR THE TWO PREPROCESSING APPROACHES

| Approach   | Chunks | Avg. Length | Max Length |
|------------|--------|-------------|------------|
| Approach 1 | 55,182 | 971.6       | 1000       |
| Approach 2 | 75,819 | 772.8       | 800        |

## B. Retrieval-Augmented Generation (RAG)

1) **Dense Embedding Generation:** Following chunk construction, all knowledge-base chunks were encoded using the BGE-M3 embedding model. The resulting dense embeddings were indexed using FAISS for efficient similarity search.

Each chunk was transformed into a normalized dense vector representation, enabling semantic similarity search through vector retrieval.

2) **Hybrid Retrieval:** To leverage both lexical and semantic matching, a hybrid retrieval strategy was employed. For each query, candidate passages were retrieved using two complementary retrievers. First, BM25 was used to identify chunks with strong keyword overlap. Second, dense retrieval was performed by encoding the query with the BGE-M3 [7] embedding model and retrieving the most similar chunk embeddings using vector similarity search.

The candidate passages obtained from both retrievers were combined through weighted score fusion. Retrieval scores were normalized and merged using predefined weights, allowing both lexical relevance and semantic similarity to contribute to the final ranking.

3) **Cross-Encoder Reranking:** The candidate passages obtained from the hybrid retrieval stage were further refined using the BGE-Reranker-v2-M3 [6] cross-encoder model. Unlike the initial retrieval stage, which independently represents queries and passages, the cross-encoder jointly processes each query–passage pair and directly estimates their relevance. Each retrieved candidate was paired with the input query and assigned a relevance score by the reranker. The candidates were then sorted according to these scores, and the highest-ranked passages were selected for context construction.

4) **Context Construction and Augmentation:** To preserve local contextual information, the passage immediately preceding each selected chunk was included alongside the selected chunks.

## C. Inference

1) **Approach 1 – Precision-Based:** As the name suggests, this combines the retrieval pipeline described in the previous section with the Gemma-4-31B-Instruct language model for answer generation. This approach was designed to prioritize answer precision and minimize hallucination by pairing the aggressively cleaned knowledge base with a context-grounded inference strategy. The answers generated by this approach were used in subsequent post-processing.

a) **Language Model:** The model configuration and inference parameters used throughout the experiments are summarized in Table II.

Table II  
GEMMA-4-31B-INSTRUCT INFERENCE CONFIGURATION

| Parameter      | Value                           |
|----------------|---------------------------------|
| Model          | Gemma-4-31B-Instruct            |
| Checkpoint     | unsloth/gemma-4-31B-it-GGUF [2] |
| Quantization   | gemma-4-31B-it-Q3_K_S.gguf      |
| Framework      | llama.cpp                       |
| Context window | 10,000 tokens                   |
| Temperature    | 0                               |
| Top-p          | 1                               |

b) **Prompt Design:** A task-specific prompt was designed to encourage context-grounded and extractive answer generation. The model was instructed to output only the final

answer span and avoid unnecessary explanations. To reduce hallucinations, the prompt explicitly required the model to return "Context -এ তথ্য নেই" when sufficient evidence could not be identified from the retrieved context, rather than generating unsupported answers. This conservative design enabled unresolved cases to be identified more reliably during post-processing. The complete prompt template is provided in Appendix A. During inference, the maximum generation length was set to 150 tokens.

c) *Retrieval Retry Strategy*: A two-stage retrieval strategy was employed during inference. The retrieval configurations used for the initial and retry stages are summarized in Table III.

Table III  
RETRIEVAL CONFIGURATION

| Parameter    | Initial | Retry |
|--------------|---------|-------|
| BM25 $k$     | 10      | 10    |
| Dense $k$    | 15      | 15    |
| Final $k$    | 6       | 10    |
| BM25 Weight  | 0.65    | 0.65  |
| Dense Weight | 0.35    | 0.35  |

Retry was triggered when the generated answer indicated insufficient contextual evidence, such as "Context -এ তথ্য নেই", "উল্লেখ নেই", or related context-missing responses. In such cases, retrieval was repeated using an expanded candidate pool ( $k = 10$ ), and the newly constructed context was provided to the language model for a second inference pass.

2) *Approach 2 – Coverage-Based*: This employs the same language model and inference configuration as Approach 1. However, it utilizes the knowledge base constructed using the second preprocessing and chunking strategy described in the preprocessing section. Whereas Approach 1 prioritizes answer precision through aggressive corpus cleaning and conservative answer generation, Approach 2 adopts a more permissive strategy intended to maximize answer coverage.

a) *Prompt Design*: A different prompt was developed for Approach 2 to encourage answer generation even when the retrieved context did not contain sufficient information to directly answer the question. Unlike Approach 1, the prompt discouraged abstention-style responses and instead instructed the model to use its pretrained knowledge to generate the most plausible answer when the retrieved context was insufficient. The prompt also instructed the model to avoid responses such as "Context-এ উল্লেখ নেই", "তথ্য নেই", or similar context-missing statements, and to return only the information explicitly requested in the question. The complete prompt template used in Approach 2 is provided in Appendix B. During inference, the maximum generation length was set to 150 tokens.

b) *Retrieval Retry Strategy*: The retrieval configuration and retry mechanism are the same as shown in Table III.

#### D. Proposed Fine-Tuning Framework

The final HybridRAG-BN framework uses Approach 2 as its primary pipeline, followed by fine-tuned answer verification, Approach 1-based fallback replacement, and DuckDuckGo-assisted retrieval for the remaining unresolved cases. Although

retrieval-augmented generation improves answer quality, incorrect or unsupported answers may still be produced. To address this issue, a LoRA-fine-tuned language model was introduced as an answer-verification component. Rather than generating answers from scratch, the model receives the question, retrieved context, and candidate answer produced by Approach 2, and evaluates whether the answer is correct and supported by the available evidence.

1) *Model Selection*: The proposed framework employs Gemma-4-31B-Instruct as the base model for fine-tuning. The fine-tuning configuration is summarized in Table IV.

Table IV  
FINE-TUNING MODEL CONFIGURATION

| Parameter               | Value                  |
|-------------------------|------------------------|
| Base Model              | Gemma-4-31B-Instruct   |
| Model Repository        | unsloth/gemma-4-31B-it |
| Fine-Tuning Method      | LoRA                   |
| Quantization            | 4-bit                  |
| Maximum Sequence Length | 2000                   |
| LoRA Rank ( $r$ )       | 16                     |
| LoRA Alpha              | 32                     |
| LoRA Dropout            | 0.0                    |
| Bias parameters         | Not trained            |
| Gradient Checkpointing  | Enabled                |
| Random Seed             | 3407                   |

2) *Training Data Construction*: The training dataset consisted of three fields: a question, its corresponding ground-truth answer, and an associated reasoning annotation. The dataset was divided into training and validation subsets using an 80/20 split with a fixed random seed.

For each training instance, the question and reasoning annotation were incorporated into an instruction-style prompt, while the ground-truth answer served as the target response.

The following prompt template was used during training:

প্রশ্ন: [Question]  
 ইঙ্গিত: [Reasoning] নির্দেশনা:  
 - ইঙ্গিত ব্যবহার করে সঠিক উত্তর নির্ধারণ করো  
 - যতটা সম্ভব পূর্ণ ও নির্ভুল উত্তর লিখবে  
 - অসম্পূর্ণ উত্তর লিখবে না  
 - শুধুমাত্র চূড়ান্ত উত্তর লিখবে  
 - অতিরিক্ত কিছু লিখবে না  
 - ব্যাখ্যা লিখবে না

3) *Fine-Tuning Procedure*: Supervised fine-tuning was performed using TRL's SFTTrainer with LoRA adaptation on a 4-bit quantized Gemma-4-31B-Instruct model. Response-only training was employed so that loss was computed only on assistant-generated tokens. The complete training configuration is summarized in Table V.

4) *Judge-Based Inference*: The proposed framework uses the answer generated by Approach 2 as a candidate prediction and applies the fine-tuned model as an answer-verification and refinement component. Rather than generating an answer from scratch, the model receives the original question, the retrieved context, and the candidate answer produced by Approach 2.

A task-specific prompt was developed to guide the verification process. The model was instructed to compare the candidate answer against the available context, remove unnecessary

Table V  
FINE-TUNING HYPERPARAMETERS

| Parameter                   | Value                        |
|-----------------------------|------------------------------|
| Training Method             | Supervised Fine-Tuning (SFT) |
| Framework                   | TRL SFTTrainer               |
| Optimizer                   | AdamW 8-bit                  |
| Epochs                      | 2                            |
| Learning Rate               | $1.5 \times 10^{-5}$         |
| Warmup Ratio                | 0.03                         |
| Per-device Batch Size       | 1                            |
| Gradient Accumulation Steps | 8                            |
| Effective Batch Size        | 8                            |
| Maximum Sequence Length     | 1000                         |
| Weight Decay                | 0.01                         |
| Learning Rate Scheduler     | Cosine                       |
| Gradient Checkpointing      | Enabled                      |
| Response-only Training      | Yes                          |
| Random Seed                 | 3407                         |
| Training Examples           | 2,400                        |
| Optimization Steps          | 600                          |
| Trainable Parameters        | 122.4M (0.39%)               |

details when appropriate, correct unsupported answers, and preserve the original answer when no confident improvement could be made. To encourage concise and precise refinements, the maximum generation length was limited to 30 tokens. The complete prompt is provided in Appendix C.

#### 5) *Post-Processing:*

a) *Merging with Approach 1 Answers:* Following judge-based inference, an additional post-processing stage was applied to the generated predictions. During manual inspection, a small number of answers were found to contain abstention-style responses such as "তথ্য নেই", "উল্লেখ নেই", and related variants indicating that the model had failed to produce a meaningful answer.

To address this issue, a rule-based filtering procedure was employed to identify such responses. For affected instances, the corresponding predictions generated by Approach 1 were used as replacement answers. This strategy was motivated by the observation that Approach 1 occasionally produced valid answers for questions where the fine-tuned verification framework remained overly conservative.

b) *DuckDuckGo (DDG) Search with Entity Extraction:* Following the initial replacement procedure, some predictions still contained the response "Context -এ তথ্য নেই". To address these remaining failures, an additional retrieval-based post-processing stage was applied.

For each affected question, an entity extraction step was first performed using the Gemma-4-31B-Instruct model. The extracted entity was then used as a query for DuckDuckGo search, and the top Wikipedia result returned by the search engine was selected. The corresponding Wikipedia article content was subsequently retrieved and provided to the language model together with the original question. A task-specific prompt was used for entity extraction and answer generation. The complete prompt is provided in Appendix D.

### III. EXPERIMENTS

To evaluate the effect of model scale on retrieval-augmented question answering performance, three other

Gemma 4 instruction-tuned models were also investigated: google/gemma-4-E2B-it, google/gemma-4-E4B-it, and google/gemma-4-26B-A4B-it. All experiments were conducted using the same retrieval-augmented generation pipeline, retrieval parameters, and prompt configuration. The Approach 2 preprocessing and chunking strategy was used throughout these experiments to ensure a consistent evaluation setting.

Qualitative inspection of the generated answers revealed a clear improvement in answer quality as model size increased. The results show a consistent improvement in both public and private F1 as model scale increases across the evaluated Gemma 4 variants, demonstrating stronger contextual understanding, and were better able to extract relevant information from the retrieved passages.

### IV. RESULTS AND ANALYSIS

The evaluation dataset consisted of 1,500 test questions. Competition rankings were determined using two evaluation splits: a public leaderboard based on approximately 69% of the test set and a private leaderboard based on the remaining 31%.

#### A. *Model Scaling Experiments*

Table VI presents the performance of the Gemma 4 models evaluated using the same retrieval-augmented generation pipeline and the Approach 2 preprocessing strategy.

Table VI  
PERFORMANCE OF DIFFERENT GEMMA 4 MODELS

| Model                  | Public F1      | Private F1     |
|------------------------|----------------|----------------|
| Gemma-4-E2B-it [5]     | 0.59634        | 0.60925        |
| Gemma-4-E4B-it [4]     | 0.60247        | 0.60727        |
| Gemma-4-26B-A4B-it [3] | <b>0.66393</b> | <b>0.68064</b> |

As shown in Table VI, these results indicate a clear positive relationship between model scale and question-answering performance. Based on this trend, Gemma-4-31B-Instruct was selected as the foundation of the proposed framework.

#### B. *Overall Performance Comparison*

We conduct an incremental ablation study to quantify the contribution of each component. Table VII presents the performance of the three evaluated approaches using the Gemma-4-31B-Instruct model. Approach 1 corresponds to the aggressively cleaned knowledge base with retrieval-augmented generation, while Approach 2 uses the alternative preprocessing strategy described previously. The proposed framework extends Approach 2 through fine-tuned answer verification and subsequent post-processing stages.

Table VII  
OVERALL TOKEN-LEVEL F1 COMPARISON

| Method                               | Public F1      | Private F1     |
|--------------------------------------|----------------|----------------|
| Approach 1                           | 0.69329        | 0.69147        |
| Approach 2                           | 0.70223        | 0.69901        |
| Approach 2 + Fine-Tuned Verification | 0.71589        | 0.72495        |
| Proposed Framework                   | <b>0.71654</b> | <b>0.72912</b> |

Approach 2 achieved higher performance than Approach 1 on both leaderboard splits, indicating that the less aggressive preprocessing strategy improved retrieval effectiveness. The proposed framework further improved performance substantially, increasing the private leaderboard score from 0.69901 to 0.72912 and the public leaderboard score from 0.70223 to 0.71654.

### C. Effect of Fine-Tuning

A comparison between the outputs of Approach 2 and the fine-tuned verification framework revealed that the fine-tuned model modified 48 of the 1,500 generated answers. These modifications included factual corrections, improved entity resolution, and more precise answer extraction. These targeted modifications produced a substantial improvement in token-level F1, suggesting that a small number of high-impact corrections accounted for a disproportionate share of the performance gain. Representative examples of answers that were altered by the fine-tuned model are presented below.

#### Example 1

Question: নাদিয়া টোনচেভা কোন দুটি উপাধি পেয়েছেন?

Approach 2: ফিদে মাস্টার এবং নারী মাস্টার

Fine-Tuned: ফিদে মাস্টার এবং নারী আন্তর্জাতিক মাস্টার

#### Example 2

Question: শার্লি টেম্পলের চলচ্চিত্রগুলো কোথায় মিলিয়ন মিলিয়ন ডলার আয় করেছে?

Approach 2: মার্কিন এবং কানাডায়

Fine-Tuned: মার্কিন যুক্তরাষ্ট্র এবং কানাডায়

The fine-tuned verification model was configured with a maximum generation length of 30 tokens to encourage concise answer refinement and maximize token-level F1 performance. While this constraint generally improved answer precision, it occasionally resulted in overly shortened answers for list type questions.

### D. Effect of Post-Processing

Predictions containing abstention-style responses such as "তথ্য নেই", "উল্লেখ নেই", or related variants were identified. The corresponding answers from Approach 1 were then examined and used as replacements whenever a more informative prediction was available. This procedure affected 11 predictions. Among them, four were correct answers.

Representative examples are shown below.

#### Example 1

Question: গ্রেসন ওয়ালার কোন সালে তার শিক্ষকতার চাকরি ছেড়ে দেন?

Approach 2 + Fine-Tuned: তথ্য নেই

Approach 1 Replacement: ২০২১ সালে

#### Example 2

Question: নাজিয়াইং মসজিদটি কোন সালে সংরক্ষিত সাংস্কৃতিক নিদর্শন হিসেবে তালিকাভুক্ত করা হয়?

Approach 2 + Fine-Tuned: প্রদত্ত তথ্যে নাজিয়াইং মসজিদটি কোন সালে সংরক্ষিত সাংস্কৃতিক নিদর্শন হিসেবে তালিকাভুক্ত করা হয়েছে তা উল্লেখ নেই

Approach 1 Replacement: ২০২১ সালে

### Example 3

Question: সুধীর চন্দ্র দাস ১৯৭৭ সালের পশ্চিমবঙ্গ বিধানসভা নির্বাচনে কত শতাংশ ভোট পেয়েছিলেন?

Approach 2 + Fine-Tuned: তথ্য নেই

Approach 1 Replacement: ১০.২৬%

Following the Approach 1 replacement stage, seven predictions still contained the response "Context-এ তথ্য নেই". These remaining cases were processed using the DuckDuckGo-assisted retrieval pipeline described previously. By leveraging external retrieval through DuckDuckGo and Wikipedia, additional information could be obtained for questions that were not successfully resolved by either the retrieval-based baseline or the fine-tuned verification framework.

Among the seven unresolved instances, five were successfully converted into answer-bearing predictions. Representative examples are shown below.

#### Example 1

Question: হেঁটা মুলারের পিতা কী পেশায় নিয়োজিত ছিলেন?

Before DDG Retrieval: Context -এ তথ্য নেই

After DDG Retrieval: ট্রাক ড্রাইভার

#### Example 2

Question: বোধিনাথ ভেলানস্বামী কোথায় সন্ন্যাস দীক্ষা লাভ করেন?

Before DDG Retrieval: Context -এ তথ্য নেই

After DDG Retrieval: শ্রীলঙ্কার আলাভেডিতে

The post-processing stage provided a further improvement over the fine-tuned verification framework, increasing the private token-level F1 score from 0.72495 to 0.72912 and the public token-level F1 score from 0.71589 to 0.71654.

## V. CONCLUSION

This paper presented a retrieval-augmented framework for Bangla knowledge-base question answering that combines hybrid retrieval, large language model inference, fine-tuned answer verification, and targeted post-processing. Two knowledge-base preprocessing and chunking strategies were investigated, followed by answer generation using Gemma-4-31B-Instruct and answer refinement through a LoRA-fine-tuned verification model. Experimental results showed that the less aggressive preprocessing strategy improved retrieval effectiveness, while the fine-tuned verification and post-processing stages further improved answer quality and overall token-level F1 performance. The final system achieved public and private leaderboard scores of 0.71654 and 0.72912. Future work may explore stronger retrieval methods, adaptive answer-verification strategies, and improved handling of cases where relevant evidence is absent from the available knowledge sources.

## VI. LIMITATIONS

The proposed framework has several limitations. The fine-tuned verification model was constrained to a maximum generation length of 30 tokens, which occasionally resulted in truncated answers for list-type questions. Additionally, the framework relies heavily on Gemma-4-31B-Instruct across

multiple pipeline stages, making it computationally expensive. Finally, model scaling experiments were conducted exclusively within the Gemma 4 family, leaving the framework’s generalizability to other model families such as Llama, Qwen, or Mistral unexplored.

#### REFERENCES

- [1] AI4Bharat, “Indic-RAG-Suite,” Hugging Face Dataset Repository. Available: <https://huggingface.co/datasets/ai4bharat/Indic-Rag-Suite> (Accessed: Jun. 2026).
- [2] Unsloth, “Gemma-4-31B-it-GGUF,” Hugging Face Model Repository. Available: <https://huggingface.co/unsloth/gemma-4-31B-it-GGUF> (Accessed: Jun. 2026).
- [3] Google, “Gemma-4-26B-A4B-it,” Hugging Face Model Repository. Available: <https://huggingface.co/google/gemma-4-26B-A4B-it> (Accessed: Jun. 2026).
- [4] Google, “Gemma-4-E4B-it,” Hugging Face Model Repository. Available: <https://huggingface.co/google/gemma-4-E4B-it> (Accessed: Jun. 2026).
- [5] Google, “Gemma-4-E2B-it,” Hugging Face Model Repository. Available: <https://huggingface.co/google/gemma-4-E2B-it> (Accessed: Jun. 2026).
- [6] BAAI, “BGE-Reranker-v2-M3,” Hugging Face Model Repository. Available: <https://huggingface.co/BAAI/bge-reranker-v2-m3> (Accessed: Jun. 2026).
- [7] BAAI, “BGE-M3,” Hugging Face Model Repository. Available: <https://huggingface.co/BAAI/bge-m3> (Accessed: Jun. 2026).

APPENDIX A  
APPROACH 1 PROMPT

A. System Prompt

The following system prompt was used during inference:

You are an ultra-precise question-answering assistant. Think carefully before answering. Output only the final answer. Do not show reasoning.

B. User Prompt

The retrieved context and input question were incorporated into the following prompt template:

প্রশ্নের semantic meaning বুঝে Context থেকে সবচেয়ে উপযুক্ত ও নির্ভুল উত্তর বের করা। প্রশ্নের শব্দ বা বাক্যাংশ repeat করবে না --- শুধুমাত্র answer part লিখবে।

গুরুত্বপূর্ণ:

- যদি প্রশ্ন specific নাম, ব্যক্তি, স্থান, তারিখ, সাল, সংখ্যা, পদবি, পুরস্কার, প্রতিষ্ঠান, ঘটনা বা নির্দিষ্ট তথ্য সম্পর্কে হয়, তাহলে শুধুমাত্র exact answer part লিখবে --- অতিরিক্ত কোনো শব্দ, ব্যাখ্যা বা পূর্ণ বাক্য লিখবে না।

উদাহরণ:

Question:

বাংলাদেশের রাজধানী কী?

Bad Answer:

বাংলাদেশের রাজধানী ঢাকা।

Correct Answer:

ঢাকা

- যদি প্রশ্ন "কেন", "কারণ", "কীভাবে", "কিসের জন্য" ধরনের হয়, তাহলে পুরো semantic context বুঝে সবচেয়ে উপযুক্ত কারণ বা short reason phrase লিখবে --- পূর্ণ বাক্য নয়, অতিরিক্ত ব্যাখ্যাও নয়।

Question:

রাহুলকে কেন স্কুল থেকে বের করে দেওয়া হয়েছিল?

Wrong Answer:

রাহুলকে কেন স্কুল থেকে বের করে দেওয়া হয়েছিল কারণ সে নকল করতে গিয়ে ধরা পড়ে।

Correct Answer:

নকল করতে গিয়ে ধরা পড়ায়

- যদি প্রশ্ন বৈজ্ঞানিক, চিকিৎসাবিজ্ঞান, অ্যানাটমি বা প্রযুক্তিগত বিষয়ের হয়, তাহলে Context-কে প্রধান উৎস হিসেবে ব্যবহার করবে এবং প্রয়োজন হলে সাধারণ বৈজ্ঞানিক জ্ঞান ব্যবহার করে সংক্ষিপ্ত ও function-based উত্তর দিবে --- সংজ্ঞা বা অপ্রয়োজনীয় ব্যাখ্যা নয়।

Question:

ফুসফুসের প্রধান কাজ কী?

Wrong Answer:

ফুসফুস মানুষের শ্বাসযন্ত্রের একটি গুরুত্বপূর্ণ অঙ্গ।

Correct Answer:

অক্সিজেন গ্রহণ ও কার্বন ডাই-অক্সাইড ত্যাগ করা

- যদি প্রশ্ন কোনো ব্যক্তির স্বভাব, আচরণ বা বৈশিষ্ট্য সম্পর্কে হয় এবং Context-এ তা সাধারণীকরণ করা যায়, তাহলে সবচেয়ে natural short trait/behavior phrase লিখবে।
- উত্তর লেখার সময় সাধারণ বানান, তারিখ, মাস, সংখ্যা, সাল, ব্যক্তি/স্থানের নাম ও প্রচলিত বাংলা রূপ ঠিক রাখবে (যেমন: ফেব্রুয়ারি, জানুয়ারি, ডিসেম্বর, বঙ্গবন্ধু, চট্টগ্রাম)। তবে meaning পরিবর্তন করবে না।

Example:

অক্টোবর → অক্টোবর

- প্রশ্নে যতটুকু চাওয়া হয়েছে ততটুকুই লিখবে --- bracket এ অতিরিক্ত নাম, উদাহরণ, দেশ, details বা list expand করবে না, যদি প্রশ্ন explicitly তা না চাওয়া হয়।

Question:

কোন মহাদেশে মরুভূমি আছে?

Wrong Answer:

এশিয়া (সাহারা, গোবি, আরব মরুভূমি)

Wrong Answer:

এশিয়া, আফ্রিকা, অস্ট্রেলিয়া --- বিভিন্ন দেশে মরুভূমি রয়েছে

Correct Answer:

এশিয়া, আফ্রিকা, অস্ট্রেলিয়া

- "কোথায়", "কোন স্থানে", "কোন অংশে", "কোথায় পাওয়া যায়", "কোথায় অবস্থিত" ধরনের প্রশ্নে যদি Context-এ বাস্তব/নির্দিষ্ট স্থান, অংশ, অধ্যায়, পরিশিষ্ট, প্রতিষ্ঠান, শহর, দেশ, ওয়েবসাইট বা location/entity স্পষ্টভাবে উল্লেখ থাকে, তাহলে সেটিই answer হিসেবে দিবে; "Context-এর অমুক লাইনে/অংশে আছে", "উল্লেখ করা হয়েছে", "দ্বিতীয় লাইনে আছে" ধরনের meta answer দিবে না।

Question:

জাতিসংঘের পরিবেশ সংক্রান্ত চুক্তিটি কোথায় উল্লেখ আছে?

Context:

জাতিসংঘের পরিবেশ সংক্রান্ত একটি বৈশ্বিক চুক্তি, যা ১৯৯২ সালে সাক্ষরিত হয়।

Wrong Answer:

Context-এ উল্লেখ আছে

Wrong Answer:

উপরের অংশে আছে

Correct Answer:

জাতিসংঘের পরিবেশ সংক্রান্ত একটি বৈশ্বিক চুক্তিতে

- যদি প্রশ্নে "কতবার", "কয়বার", "কতটি", "কয়টি", "মোট", "সংখ্যা", "কতজন", "কত বছর" ইত্যাদি count বোঝায়, তাহলে Context-এর তথ্য গুনে শুধুমাত্র final সংখ্যা/পরিমাণ লিখবে --- তালিকা বা সাল repeat করবে না; Context-এ আলাদাভাবে count লেখা না থাকলেও তথ্য থেকে count বের করবে।

কঠোর নিয়ম:

- 1) শুধুমাত্র Context ব্যবহার করবে।
- 2) প্রশ্নের অর্থ গভীরভাবে বুঝবে।

- 3) পুরো Context বুঝে উত্তর দেবে।
- 4) উত্তর sentence আকারে লিখবে না।
- 5) শুধুমাত্র answer part / answer span লিখবে।
- 6) "ব্রিটিশ আমলে...", "প্রাপ্ত তথ্য অনুযায়ী...", "Context অনুযায়ী..." এভাবে শুরু করবে না।
- 7) অপ্রয়োজনীয় শব্দ যোগ করবে না।
- 8) প্রশ্ন repeat করবে না।
- 9) প্রশ্ন যদি "কেন" হয়, semantic context বুঝে সবচেয়ে উপযুক্ত কারণ বের করবে।
- 10) উত্তর সংক্ষিপ্ত, precise এবং natural হবে।
- 11) এক লাইনে শুধু final answer দিবে।
- 12) Context-এর বাইরে কিছু বানাবে না।

Note:

Context-এ "৪ টি ভাষা", " n টি ভাষা" এরকম Wikipedia থেকে direct copy করা translation option গুলো রয়ে যেতে পারে --- এগুলো ignore করিও, এগুলো মূল তথ্য বা answer-এর অংশ না।

Note:

যদি Context-এ প্রশ্নের উত্তর স্পষ্টভাবে না থাকে বা পর্যাপ্ত তথ্য না পাওয়া যায়, তাহলে শুধুমাত্র "Context-এ তথ্য নেই" লিখবে --- অতিরিক্ত ব্যাখ্যা, অনুমান বা অন্য কোনো বাক্য লিখবে না।

Context:

{context}

Question:

{question}

Answer:

### C. Inference Configuration

- Model: Gemma-4-31B-Instruct
- Checkpoint: unsloth/gemma-4-31B-it-GGUF
- Quantized file: gemma-4-31B-it-Q3\_K\_S.gguf
- Framework: llama.cpp
- Context window: 10,000 tokens
- Temperature: 0
- Top-p: 1
- Maximum generation length: 150 tokens



APPENDIX B  
APPROACH 2 PROMPT

A. System Prompt

The following system prompt was used during inference:

You are an ultra-precise question answering assistant. Think carefully before answering. Output only the final answer. Do not show reasoning.

B. User Prompt

The retrieved context and input question were incorporated into the following prompt template:

প্রশ্নের semantic meaning বুঝে Context থেকে সবচেয়ে উপযুক্ত ও নির্ভুল উত্তর বের করা। প্রশ্নের শব্দ বা বাক্যাংশ repeat করবে না --- শুধুমাত্র answer part লিখবে।

গুরুত্বপূর্ণ:

- যদি প্রশ্ন specific নাম, ব্যক্তি, স্থান, তারিখ, সাল, সংখ্যা, পদবি, পুরস্কার, প্রতিষ্ঠান, ঘটনা বা নির্দিষ্ট তথ্য সম্পর্কে হয়, তাহলে শুধুমাত্র exact answer part লিখবে --- অতিরিক্ত কোনো শব্দ, ব্যাখ্যা বা পূর্ণ বাক্য লিখবে না।

উদাহরণ:

Question:

বাংলাদেশের রাজধানী কী?

Bad Answer:

বাংলাদেশের রাজধানী ঢাকা।

Correct Answer:

ঢাকা

- যদি প্রশ্ন 'কেন', 'কারণ', 'কীভাবে', 'কিসের জন্য' ধরনের হয়, তাহলে পুরো semantic context বুঝে সবচেয়ে উপযুক্ত কারণ বা short reason phrase লিখবে --- পূর্ণ বাক্য নয়, অতিরিক্ত ব্যাখ্যাও নয়।

Question:

রাহুলকে কেন স্কুল থেকে বের করে দেওয়া হয়েছিল?

Wrong Answer:

রাহুলকে কেন স্কুল থেকে বের করে দেওয়া হয়েছিল কারণ সে নকল করতে গিয়ে ধরা পড়ে।

Correct Answer:

নকল করতে গিয়ে ধরা পড়ায়

- যদি প্রশ্ন বৈজ্ঞানিক, চিকিৎসাবিজ্ঞান, অ্যানাটমি বা প্রযুক্তিগত বিষয়ের হয়, তাহলে Context-কে প্রধান উৎস হিসেবে ব্যবহার করবে এবং প্রয়োজন হলে সাধারণ বৈজ্ঞানিক জ্ঞান ব্যবহার করে সংক্ষিপ্ত ও function-based উত্তর দিবে --- সংজ্ঞা বা অপ্রয়োজনীয় ব্যাখ্যা নয়।

Question:

ফুসফুসের প্রধান কাজ কী?

Wrong Answer:

ফুসফুস মানুষের শ্বাসযন্ত্রের একটি গুরুত্বপূর্ণ অঙ্গ।

Correct Answer:

অক্সিজেন গ্রহণ ও কার্বন ডাই-অক্সাইড ত্যাগ করা

- যদি প্রশ্ন কোনো ব্যক্তির স্বভাব, আচরণ বা বৈশিষ্ট্য সম্পর্কে হয় এবং Context-এ তা সাধারণীকরণ করা যায়, তাহলে সবচেয়ে natural short trait/behavior phrase লিখবে।
- উত্তর লেখার সময় সাধারণ বানান, তারিখ, মাস, সংখ্যা, সাল, ব্যক্তি/স্থানের নাম ও প্রচলিত বাংলা রূপ ঠিক রাখবে (যেমন: ফেব্রুয়ারি, জানুয়ারি, ডিসেম্বর, বঙ্গবন্ধু, চট্টগ্রাম)। তবে meaning পরিবর্তন করবে না।

Example:

অক্টোবর → অক্টোবর

- প্রশ্নে যতটুকু চাওয়া হয়েছে ততটুকুই লিখবে --- bracket এ অতিরিক্ত নাম, উদাহরণ, দেশ, details বা list expand করবে না, যদি প্রশ্ন explicitly তা না চাওয়া হয়।

Question:

কোন মহাদেশে মরুভূমি আছে?

Wrong Answer:

এশিয়া (সাহারা, গোবি, আরব মরুভূমি)

Wrong Answer:

এশিয়া, আফ্রিকা, অস্ট্রেলিয়া --- বিভিন্ন দেশে মরুভূমি রয়েছে

Correct Answer:

এশিয়া, আফ্রিকা, অস্ট্রেলিয়া

- 'কোথায়', 'কোন স্থানে', 'কোন অংশে', 'কোথায় পাওয়া যায়', 'কোথায় অবস্থিত' ধরনের প্রশ্নে যদি Context-এ বাস্তু/নির্দিষ্ট স্থান, অংশ, অধ্যায়, পরিশিষ্ট, প্রতিষ্ঠান, শহর, দেশ, ওয়েবসাইট বা location/entity স্পষ্টভাবে উল্লেখ থাকে, তাহলে সেটিই answer হিসেবে দিবে; Context-এর অমুক লাইনে/অংশে আছে', 'উল্লেখ করা হয়েছে', 'দ্বিতীয় লাইনে আছে' ধরনের meta answer দিবে না।

কঠোর নিয়ম:

- 1) শুধুমাত্র Context ব্যবহার করবে।
- 2) প্রশ্নের অর্থ গভীরভাবে বুঝবে।
- 3) পুরো Context বুঝে উত্তর দেবে।
- 4) উত্তর sentence আকারে লিখবে না।
- 5) শুধুমাত্র answer part / answer span লিখবে।
- 6) 'ব্রিটিশ আমলে...', 'প্রাপ্ত তথ্য অনুযায়ী...', 'Context অনুযায়ী...' এভাবে শুরু করবে না।
- 7) অপ্রয়োজনীয় শব্দ যোগ করবে না।
- 8) প্রশ্ন repeat করবে না।
- 9) প্রশ্ন যদি 'কেন' হয়, semantic context বুঝে সবচেয়ে উপযুক্ত কারণ বের করবে।
- 10) উত্তর সংক্ষিপ্ত, precise এবং natural হবে।
- 11) এক লাইনে শুধু final answer দিবে।
- 12) Context-এর বাইরে কিছু বানাবে না।

খুব গুরুত্বপূর্ণ:

- যদি Context-এ উত্তর স্পষ্টভাবে না থাকে, তাহলে নিজের pretrained/general knowledge ব্যবহার করে সবচেয়ে সম্ভাব্য সংক্ষিপ্ত answer দিবে; 'Context-এ উল্লেখ নেই', 'তথ্য নেই', 'উত্তর পাওয়া যায়নি', 'প্রদত্ত তথ্য অনুযায়ী' --- এ ধরনের wording final answer-এ কখনো ব্যবহার করবে না।

- Final answer এমনভাবে লিখবে যেন expected ground-truth answer-এর সাথে token overlap সর্বোচ্চ হয় --- অতিরিক্ত token precision কমায়, missing token recall কমায়।
- সবচেয়ে ছোট কিন্তু সম্পূর্ণ semantic answer দিবে --- উদাহরণ বা extra explanation, prefix, suffix, bracket, expansion যোগ করবে না।
- যদি answer এক বা কয়েকটি শব্দে দেওয়া সম্ভব হয়, তাহলে শুধু সেই minimal answer span লিখবে।
- multiple possible wording থাকলে সবচেয়ে standard, common এবং short wording ব্যবহার করবে।

Note:

Context-এ ৪ টি ভাষা'', ৩ টি ভাষা''      Wikipedia translation noise থাকতে পারে --- এগুলো ignore করিও।

Context:

{context}

Question:

{question}

Answer:

### C. Inference Configuration

The same inference configuration used in Approach 1 was employed for Approach 2.

- Model: Gemma-4-31B-Instruct
- Checkpoint: unsloth/gemma-4-31B-it-GGUF
- Quantized file: gemma-4-31B-it-Q3\_K\_S.gguf
- Framework: llama.cpp
- Context window: 10,000 tokens
- Temperature: 0
- Top-p: 1
- Maximum generation length: 150 tokens

APPENDIX C  
APPROACH 3 PROMPT (FINE-TUNED JUDGE)

*A. Purpose*

The prompt presented in this appendix was used during the judge-based inference stage of the proposed fine-tuning framework. Unlike Approaches 1 and 2, where the language model directly generated answers from retrieved context, the fine-tuned model operated as a post-processing component.

The objective of the prompt was to verify and refine candidate answers generated by the Approach 2 pipeline. For each instance, the model received the original question, the retrieved context, and the candidate answer produced by Approach 2. The model was instructed to preserve correct answers whenever possible and perform modifications only when sufficient contextual evidence supported a refinement.

*B. User Prompt*

The retrieved context and candidate answer were incorporated into the following prompt template:

তোমার কাজ হলো Question, Context এবং Candidate Answer দেখে final competition answer বের করা।

নিয়ম:

- Candidate answer যদি already ভালো হয়, একই answer রাখবে।
- Candidate answer unnecessarily বড় হলে ছোট করবে।
- নতুন extra detail যোগ করবে না।
- Bracket এর ভিতরে extra তথ্য যোগ করবে না।

উদাহরণ:

ভালো: ১৭৭ ফুট

খারাপ: ১৭৭ ফুট (৫৪ মিটার)

- যতটা সম্ভব minimal answer span দিবে।
- তবে answer incomplete করা যাবে না।
- Context অনুযায়ী candidate answer verify করবে।
- Context mismatch হলে answer ঠিক করবে।
- Question repeat করবে না।
- Explanation দিবে না।
- Sentence লিখবে না।
- শুধুমাত্র final answer দিবে।

খুব গুরুত্বপূর্ণ:

- যদি Context দিয়ে answer confidently verify বা improve করা না যায়, তাহলে Candidate Answer exactly একই রাখবে।

Question:

{question}

Context:

{context}

Candidate Answer:

{current\_answer}

Final Answer:

*C. Inference Configuration*

The fine-tuned model was loaded by combining the Gemma-4-31B-Instruct base model with the LoRA adapters obtained during supervised fine-tuning.

- Base Model: Gemma-4-31B-Instruct
- Model Repository: unsloth/gemma-4-31B-it
- Fine-Tuning Method: LoRA
- Quantization: 4-bit
- Maximum Sequence Length: 10,000
- Decoding Strategy: Greedy Decoding
- Temperature: 0.0
- Top-p: 1.0
- Repetition Penalty: 1.05
- Maximum generation length: 30 Tokens

*D. Inference Inputs*

Each inference instance consisted of the following components:

- Question
- Retrieved Context (Approach 2)
- Candidate Answer (Approach 2 Output)

The model generated a refined answer which was subsequently post-processed and validated. When refinement failed, the original candidate answer produced by Approach 2 was retained.

## APPENDIX D

### DUCKDUCKGO-ASSISTED RETRIEVAL PROMPTS

#### A. Entity Extraction Prompt

The following prompt was used to extract the primary entity associated with a question. The extracted entity was subsequently used as a DuckDuckGo search query to identify relevant Wikipedia articles.

তুমি একজন expert entity extractor.

কাজ:

প্রশ্নের শুধুমাত্র MAIN SUBJECT ENTITY বের করো।

অত্যন্ত গুরুত্বপূর্ণ নিয়ম:

- 1) সবসময় PERSON / ORGANIZATION / PLACE / THING extract করবে যেটা প্রশ্নটি সম্পর্কে।
- 2) কখনো extract করবে না:
  - উত্তর
  - প্রশ্নে জিজ্ঞাসিত location
  - তারিখ
  - ঘটনা
  - attribute
- 3) 'কোথায়' প্রশ্নে location নয়, প্রশ্নটি কার সম্পর্কে সেই entity extract করবে।
- 4) 'কখন' প্রশ্নে তারিখ নয়, প্রশ্নটি কী সম্পর্কে সেই entity extract করবে।
- 5) সম্পূর্ণ official নাম রাখবে।

Output format:

১ম লাইন = বাংলা entity

২য় লাইন = English entity

উদাহরণ:

Question:

ঢাকা বিশ্ববিদ্যালয় কত সালে প্রতিষ্ঠিত হয়?

Answer:

ঢাকা বিশ্ববিদ্যালয়

Dhaka University

Question:

রবীন্দ্রনাথ ঠাকুর কোন পুরস্কার পেয়েছিলেন?

Answer:

রবীন্দ্রনাথ ঠাকুর

Rabindranath Tagore

Question:

জাতিসংঘের মহাসচিব কে?

Answer:

জাতিসংঘ

United Nations

কঠোর নিয়ম:

- 1) সবসময় সম্পূর্ণ FULL NAME দিবে।
- 2) কখনো নাম সংক্ষিপ্ত করবে না।

CORRECT:

কেন উইলিয়ামসন

সাকিব আল হাসান

রবীন্দ্রনাথ ঠাকুর

শেখ মুজিবুর রহমান

WRONG:

উইলিয়ামসন

সাকিব

রবীন্দ্রনাথ

মুজিব

Question:

{question}

#### B. Answer Generation Prompt

After retrieval, the retrieved Wikipedia content and the original question were incorporated into the following prompt template to generate an answer from the external context.

প্রশ্নের semantic meaning বুঝে Context থেকে সবচেয়ে উপযুক্ত উত্তর বের করো।

Question:

{question}

Context:

{context}

গুরুত্বপূর্ণ:

- শুধুমাত্র answer লিখবে
- sentence না
- reasoning না
- explanation না

#### C. Inference Configuration

The same Gemma-4-31B-Instruct model used in Approach 1 was employed during this stage.

- Base Model: Gemma-4-31B-Instruct
- Checkpoint: unsloth/gemma-4-31B-it-GGUF
- Quantized file: gemma-4-31B-it-Q3\_K\_S.gguf
- Framework: llama.cpp
- Temperature: 0
- Top-p: 1
- Maximum generation length: 80 Tokens

#### D. Application Scope

This retrieval procedure was applied only to predictions that still contained the response "Context-এ তথ্য নেই" after the previous post-processing stage. A total of seven such instances were identified and processed using the DuckDuckGo-assisted retrieval pipeline.

For each affected question, an entity was first extracted using the entity extraction prompt. The extracted entity was then used as a DuckDuckGo query, and the top Wikipedia result returned by the search engine was retrieved. The resulting article content was subsequently provided to the

language model together with the original question to generate a replacement answer.

Only answers generated from the DuckDuckGo-assisted retrieval pipeline were used during this stage.